

# Методы оптимизации. Семинар 3.

## Векторное дифференцирование

Александр Катруца

Московский физико-технический институт

15 сентября 2020 г.

# Напоминание

- ▶ Сопряжённые конусы
- ▶ Свойства сопряжённых множеств
- ▶ Опорная гиперплоскость
- ▶ Разделяющая гиперплоскость
- ▶ Лемма Фаркаша


# Основные определения

Более подробно смотрите [здесь](#). Пусть  $f : D \rightarrow E$ , производная  $\frac{\partial f}{\partial x} \in G$ :

$D$	$E$	$G$	Название
$\mathbb{R}$	$\mathbb{R}$	$\mathbb{R}$	Производная, $f'(x)$
$\mathbb{R}^n$	$\mathbb{R}$	$\mathbb{R}^n$	Градиент, $\frac{\partial f}{\partial x_i}$
$\mathbb{R}^n$	$\mathbb{R}^m$	$\mathbb{R}^{m \times n}$	Матрица Якоби, $\frac{\partial f_i}{\partial x_j}$
$\mathbb{R}^{m \times n}$	$\mathbb{R}$	$\mathbb{R}^{m \times n}$	$\frac{\partial f}{\partial x_{ij}}$

Также квадратная  $n \times n$  матрица вторых производных  $\mathbf{H} = [h_{ij}]$  в случае  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  называется гессиан и равна 
$$h_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}.$$

# Основная техника



# Примеры

1. Линейная функция:  $f(\mathbf{x}) = \mathbf{c}^\top \mathbf{x}$
2. Квадратичная форма:  $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x}$
3. Квадрат  $\ell_2$  нормы разности:  $f(\mathbf{x}) = \|\mathbf{A} \mathbf{x} - \mathbf{b}\|_2^2$
4. Детерминант:  $f(\mathbf{X}) = \det \mathbf{X}$
5. След:  $f(\mathbf{X}) = \text{trace}(\mathbf{A} \mathbf{X} \mathbf{B})$
6.  $f(\mathbf{x}) = (\mathbf{x} - \mathbf{A} \mathbf{s})^\top \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s})$
7.  $f(\mathbf{A}) = (\mathbf{x} - \mathbf{A} \mathbf{s})^\top \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s})$
8.  $f(\mathbf{s}) = (\mathbf{x} - \mathbf{A} \mathbf{s})^\top \mathbf{W} (\mathbf{x} - \mathbf{A} \mathbf{s})$

## Сложная функция: скалярный случай

- ▶ Пусть  $f(\mathbf{x}) = g(u(\mathbf{x}))$ , тогда  $f'(\mathbf{x}) = \frac{\partial g}{\partial u} \frac{\partial u}{\partial \mathbf{x}}$
- ▶ Важно смотреть на размерности и понимать как записывать  $\frac{\partial g}{\partial u}$ .

# Сложная функция: скалярный случай

- ▶ Пусть  $f(\mathbf{x}) = g(u(\mathbf{x}))$ , тогда  $f'(\mathbf{x}) = \frac{\partial g}{\partial u} \frac{\partial u}{\partial \mathbf{x}}$
- ▶ Важно смотреть на размерности и понимать как записывать  $\frac{\partial g}{\partial u}$ .

## Примеры

1.  $\ell_2$  норма вектора:  $f(\mathbf{x}) = \|\mathbf{x}\|_2$
2. Экспонента:  $f(\mathbf{x}) = -e^{-\mathbf{x}^\top \mathbf{x}}$

# Сложная функция: векторный случай

- ▶  $f(\mathbf{x}) = g(h(\mathbf{x}))$ , где  $h : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ,  $g : \mathbb{R}^m \rightarrow \mathbb{R}$
- ▶  $\frac{\partial f}{\partial x_k} = \sum_j \frac{\partial g}{\partial h_j} \frac{\partial h_j}{\partial x_k} = \sum_j J_{jk} \frac{\partial g}{\partial h_j}$  —  $k$ -ый элемент градиента
- ▶  $\frac{\partial f}{\partial \mathbf{x}} = \mathbf{J}^\top \frac{\partial g}{\partial \mathbf{h}}$ , где  $\mathbf{J}$  — якобиан  $h$



# Сложная функция: векторный случай

- ▶  $f(\mathbf{x}) = g(h(\mathbf{x}))$ , где  $h : \mathbb{R}^n \rightarrow \mathbb{R}^m$ ,  $g : \mathbb{R}^m \rightarrow \mathbb{R}$
- ▶  $\frac{\partial f}{\partial x_k} = \sum_j \frac{\partial g}{\partial h_j} \frac{\partial h_j}{\partial x_k} = \sum_j J_{jk} \frac{\partial g}{\partial h_j}$  —  $k$ -ый элемент градиента
- ▶  $\frac{\partial f}{\partial \mathbf{x}} = \mathbf{J}^\top \frac{\partial g}{\partial \mathbf{h}}$ , где  $\mathbf{J}$  — якобиан  $h$

## Примеры

- ▶  $h(\mathbf{x}) = \mathbf{A}\mathbf{x} - \mathbf{b}$ ,  $g(\mathbf{u}) = \|\mathbf{u}\|_2^2$ . Найти  $f'(\mathbf{x})$
- ▶  $h(\mathbf{x}) = \cos(\mathbf{x})$  поэлементно,  $g(\mathbf{u}) = \sum_i u_i$ . Найти  $\frac{\partial f}{\partial \mathbf{x}}$

# Chain rule and autodiff<sup>1</sup>

## Мотивирующий пример

- ▶  $f = h(g(\mathbf{x}))$ , где  $h : \mathbb{R}^k \rightarrow \mathbb{R}^m$ ,  $g : \mathbb{R}^n \rightarrow \mathbb{R}^k$
- ▶  $\mathbf{J}_f = \mathbf{J}_h(g(\mathbf{x}))\mathbf{J}_g(\mathbf{x})$  или  $J_f^{(i,j)} = \frac{\partial f_i}{\partial x_j} = \sum_{l=1}^k \frac{\partial h_i}{\partial g_k} \frac{\partial g_k}{\partial x_j}$

---

<sup>1</sup>Griewank A., Walther A. Evaluating derivatives: principles and techniques of algorithmic differentiation. – Society for Industrial and Applied Mathematics, 2008.

# Chain rule and autodiff<sup>1</sup>

## Мотивирующий пример

- ▶  $f = h(g(\mathbf{x}))$ , где  $h : \mathbb{R}^k \rightarrow \mathbb{R}^m$ ,  $g : \mathbb{R}^n \rightarrow \mathbb{R}^k$
- ▶  $\mathbf{J}_f = \mathbf{J}_h(g(\mathbf{x}))\mathbf{J}_g(\mathbf{x})$  или  $J_f^{(i,j)} = \frac{\partial f_i}{\partial x_j} = \sum_{l=1}^k \frac{\partial h_i}{\partial g_k} \frac{\partial g_k}{\partial x_j}$

## Обобщение

- ▶  $f = f_L \circ \dots \circ f_1$  — представление в виде графа
- ▶  $\mathbf{J}_f = \mathbf{J}_L \cdot \dots \cdot \mathbf{J}_1$

---

<sup>1</sup>Griewank A., Walther A. Evaluating derivatives: principles and techniques of algorithmic differentiation. – Society for Industrial and Applied Mathematics, 2008.

# Chain rule and autodiff<sup>1</sup>

## Мотивирующий пример

- ▶  $f = h(g(\mathbf{x}))$ , где  $h : \mathbb{R}^k \rightarrow \mathbb{R}^m$ ,  $g : \mathbb{R}^n \rightarrow \mathbb{R}^k$
- ▶  $\mathbf{J}_f = \mathbf{J}_h(g(\mathbf{x}))\mathbf{J}_g(\mathbf{x})$  или  $J_f^{(i,j)} = \frac{\partial f_i}{\partial x_j} = \sum_{l=1}^k \frac{\partial h_i}{\partial g_k} \frac{\partial g_k}{\partial x_j}$

## Обобщение

- ▶  $f = f_L \circ \dots \circ f_1$  — представление в виде графа
- ▶  $\mathbf{J}_f = \mathbf{J}_L \cdot \dots \cdot \mathbf{J}_1$

## Способы вычисления $\mathbf{J}_f$

- ▶ Справа налево — forward mode
- ▶ Слева направо — backward mode

---

<sup>1</sup>Griewank A., Walther A. Evaluating derivatives: principles and techniques of algorithmic differentiation. – Society for Industrial and Applied Mathematics, 2008.

# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть  
вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

## Реализация

- Выбираем элемент  $x_j$

# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем элемент  $x_j$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_j$  —  $j$ -ый орт

# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем элемент  $x_j$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_j$  —  $j$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1 \mathbf{u}$  справа налево



# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем элемент  $x_j$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_j$  —  $j$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1 \mathbf{u}$  **справа налево**
- ▶ Умножение происходит одновременно с вычислением  $f_L \circ \dots \circ f_1$

# Forward mode

## Основная идея

Вычислить  $\frac{\partial f_i}{\partial x_k}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ый столбец матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем элемент  $x_j$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_j$  —  $j$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1 \mathbf{u}$  **справа налево**
- ▶ Умножение происходит одновременно с вычислением  $f_L \circ \dots \circ f_1$
- ▶ Для каждой  $f_i$  необходимо реализовать действие самой функции и умножение  $\mathbf{J}_i$  на вектор

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- Выбираем компоненту  $f_k$

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем компоненту  $f_k$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_k$  —  $k$ -ый орт

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем компоненту  $f_k$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_k$  —  $k$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{u}^\top \mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1$  слева направо

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем компоненту  $f_k$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_k$  —  $k$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{u}^\top \mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1$  **слева направо**
- ▶ Сначала вычисляем  $f$ , потом произведение выше — два обхода графа

# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем компоненту  $f_k$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_k$  —  $k$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{u}^\top \mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1$  **слева направо**
- ▶ Сначала вычисляем  $f$ , потом произведение выше — два обхода графа
- ▶ Для каждой  $f_i$  необходимо реализовать действие самой функции и умножение  $\mathbf{J}_i^\top$  на вектор



# Backward mode или backpropagation

## Основная идея

Вычислить  $\frac{\partial f_k}{\partial x_i}$  для всех  $i$  и для заданного  $k$ , то есть вычислить  $j$ -ую строку матрицы  $\mathbf{J}_f$

## Реализация

- ▶ Выбираем компоненту  $f_k$
- ▶ Задаём вектор  $\mathbf{u} = \mathbf{e}_k$  —  $k$ -ый орт
- ▶ Умножаем рекурсивно  $\mathbf{u}^\top \mathbf{J}_L \dots \mathbf{J}_2 \mathbf{J}_1$  **слева направо**
- ▶ Сначала вычисляем  $f$ , потом произведение выше — два обхода графа
- ▶ Для каждой  $f_i$  необходимо реализовать действие самой функции и умножение  $\mathbf{J}_i^\top$  на вектор

Если  $m = 1$ , то  $\mathbf{u} = 1$  и результат совпадает с градиентом!

# Forward vs backward modes

## Вычислительная сложность

- ▶ Forward mode:  $C(f(\mathbf{x}), \mathbf{J}\mathbf{u}) \leq 2.5C(f(\mathbf{x}))$
- ▶ Backward mode:  $C(f(\mathbf{x}), \mathbf{J}^\top \mathbf{u}) \leq 4C(f(\mathbf{x}))$

# Forward vs backward modes

## Вычислительная сложность

- ▶ Forward mode:  $C(f(\mathbf{x}), \mathbf{J}\mathbf{u}) \leq 2.5C(f(\mathbf{x}))$
- ▶ Backward mode:  $C(f(\mathbf{x}), \mathbf{J}^\top \mathbf{u}) \leq 4C(f(\mathbf{x}))$

## Требуемая память

- ▶ Forward mode: не требует, все вычисления делаются в процессе вычисления  $f$
- ▶ Backward mode: требует, промежуточные значения  $f_{i-1}$  надо сохранить для вычисления  $\mathbf{J}_i^\top \mathbf{u}$

# Forward vs backward modes

## Вычислительная сложность

- ▶ Forward mode:  $C(f(\mathbf{x}), \mathbf{J}\mathbf{u}) \leq 2.5C(f(\mathbf{x}))$
- ▶ Backward mode:  $C(f(\mathbf{x}), \mathbf{J}^\top \mathbf{u}) \leq 4C(f(\mathbf{x}))$

## Требуемая память

- ▶ Forward mode: не требует, все вычисления делаются в процессе вычисления  $f$
- ▶ Backward mode: требует, промежуточные значения  $f_{i-1}$  надо сохранить для вычисления  $\mathbf{J}_i^\top \mathbf{u}$

## Вывод

- ▶ Если  $m \ll n$ , используйте backward mode
- ▶ Если  $m \geq n$ , используйте forward mode

Различные реализации могут оптимизировать промежуточные вычисления!

## Пример

Для функции  $f(x_1, x_2) = \cos^2(x_1 + x_2^3)$ . Найти  $\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}$   
 $f(x_1, x_2) = f_1(f_2(f_3(x_1, f_4(x_2))))$

# Пример

Для функции  $f(x_1, x_2) = \cos^2(x_1 + x_2^3)$ . Найти  $\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}$   
 $f(x_1, x_2) = f_1(f_2(f_3(x_1, f_4(x_2))))$

Forward mode

- ▶ Вычислим  $\frac{\partial f}{\partial x_2}$
- ▶  $w_1 = x_1, w_2 = x_2$
- ▶  $\frac{\partial w_1}{\partial x_1} = 0, \frac{\partial w_2}{\partial x_2} = 1$
- ▶  $w_3 = 3w_2^2 \frac{\partial w_2}{\partial x_2}$
- ▶  $w_4 = \frac{\partial w_1}{\partial x_1} + w_3$
- ▶  $w_5 = -\sin(w_1 + w_2^3)w_4$
- ▶  $w_6 = 2 \cos(w_1 + w_2^3)w_5$
- ▶  $w_6 = \frac{\partial f}{\partial x_2}$

# Пример

Для функции  $f(x_1, x_2) = \cos^2(x_1 + x_2^3)$ . Найдите  $\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}$   
 $f(x_1, x_2) = f_1(f_2(f_3(x_1, f_4(x_2))))$

## Forward mode

- ▶ Вычислим  $\frac{\partial f}{\partial x_2}$
- ▶  $w_1 = x_1, w_2 = x_2$
- ▶  $\frac{\partial w_1}{\partial x_1} = 0, \frac{\partial w_2}{\partial x_2} = 1$
- ▶  $w_3 = 3w_2^2 \frac{\partial w_2}{\partial x_2}$
- ▶  $w_4 = \frac{\partial w_1}{\partial x_1} + w_3$
- ▶  $w_5 = -\sin(w_1 + w_2^3)w_4$
- ▶  $w_6 = 2 \cos(w_1 + w_2^3)w_5$
- ▶  $w_6 = \frac{\partial f}{\partial x_2}$

## Backward mode

- ▶  $w_0 = 1$
- ▶  $w_1 = \frac{\partial f_1}{\partial f_2} w_0 = 2f_2 w_0$
- ▶  $w_2 = \frac{\partial f_2}{\partial f_3} w_1 = -\sin(f_3)w_1$
- ▶  $w_3 = \frac{\partial f}{\partial x_1} = \frac{\partial f_3}{\partial x_1} w_2 = w_2$
- ▶  $w_4 = \frac{\partial f_3}{\partial f_4} w_2$
- ▶  $w_5 = \frac{\partial f}{\partial x_2} = \frac{\partial f_4}{\partial x_2} w_4 = 3x_2^2 w_4$

## Умножение гессиана на вектор

- ▶ Дан вектор  $\mathbf{z}$ , нужно вычислить  $f''(\mathbf{x})\mathbf{z}$



## Умножение гессиана на вектор

- ▶ Дан вектор  $\mathbf{z}$ , нужно вычислить  $f''(\mathbf{x})\mathbf{z}$
- ▶ Вспомним, что  $f''(\mathbf{x}) = (f'(\mathbf{x}))'$

## Умножение гессиана на вектор

- ▶ Дан вектор  $\mathbf{z}$ , нужно вычислить  $f''(\mathbf{x})\mathbf{z}$
- ▶ Вспомним, что  $f''(\mathbf{x}) = (f'(\mathbf{x}))'$
- ▶ Вычислим градиент  $f'(\mathbf{x})$  с помощью backward mode

## Умножение гессиана на вектор

- ▶ Дан вектор  $\mathbf{z}$ , нужно вычислить  $f''(\mathbf{x})\mathbf{z}$
- ▶ Вспомним, что  $f''(\mathbf{x}) = (f'(\mathbf{x}))'$
- ▶ Вычислим градиент  $f'(\mathbf{x})$  с помощью backward mode
- ▶ И вычислим  $f''(\mathbf{x})\mathbf{z} = \mathbf{J}_{f'}\mathbf{z}$  с помощью forward mode

# Умножение гессиана на вектор

- ▶ Дан вектор  $\mathbf{z}$ , нужно вычислить  $f''(\mathbf{x})\mathbf{z}$
- ▶ Вспомним, что  $f''(\mathbf{x}) = (f'(\mathbf{x}))'$
- ▶ Вычислим градиент  $f'(\mathbf{x})$  с помощью backward mode
- ▶ И вычислим  $f''(\mathbf{x})\mathbf{z} = \mathbf{J}_{f'}\mathbf{z}$  с помощью forward mode

## Почему это хорошо?

- ▶ Полный гессиан не хранится — экономия памяти
- ▶ Выбор режимов вычисления градиентов и умножения гессиана на вектор обоснованы размерностями входа и выхода функций  $f$  и  $f'$

# Резюме

- ▶ Производная по скаляру
- ▶ Производная по вектору
- ▶ Производная по матрице
- ▶ Производная сложной функции
- ▶ Автоматическое дифференцирование